

Detección de jugadores y estimación de posesión de pelota en video de fútbol mediante visión por computadora

Facundo Rivas
CEIA – Visión por Computadora II
Universidad de Buenos Aires
Buenos Aires, Argentina

Franco Curcho
CEIA – Visión por Computadora II
Universidad de Buenos Aires
Buenos Aires, Argentina

Juan Ignacio Teich
CEIA – Visión por Computadora II
Universidad de Buenos Aires
Buenos Aires, Argentina

Resumen—Se presenta un pipeline de visión por computadora que, a partir de videos de fútbol, detecta jugadores, árbitros y pelota, asigna cada jugador a su equipo, mantiene identidades estables en el tiempo y estima la posesión de la pelota, produciendo métricas agregadas y un video con overlay de visualización. El sistema se estructura en tres etapas: detección mediante YOLO26m, tracking con ByteTrack, y estimación de posesión basada en proximidad con modelo de estado (*hold* + histéresis). La asignación de equipo, inicialmente planteada por clustering en espacio de color HSV, resultó inviable en la práctica ($\sim 60\%$ de accuracy, equivalente al azar). Se resolvió utilizando embeddings visuales SigLIP, alcanzando 92–98 % de accuracy. La posesión, evaluada contra ground truth manual, alcanza $\sim 76\%$ de accuracy frame a frame. El trabajo documenta cada decisión de diseño con evidencia experimental cuantitativa.

Index Terms—detección de objetos, YOLO, tracking, posesión de pelota, fútbol, visión por computadora, embeddings visuales, SigLIP

I. INTRODUCCIÓN

El análisis automático de video de fútbol es un problema de creciente interés tanto en la industria deportiva como en la comunidad de visión por computadora. Estimar métricas tácticas como la posesión de pelota a partir de video requiere resolver múltiples subproblemas encadenados: detección de objetos (jugadores, árbitro, pelota), asignación de cada jugador a su equipo, seguimiento temporal de identidades y, finalmente, la estimación de quién controla la pelota en cada instante.

Este trabajo presenta un pipeline completo de tres etapas que aborda estos desafíos de manera integrada:

1. **Detección y asignación de equipo:** detección de objetos con YOLO y asignación de equipo mediante embeddings visuales.
2. **Tracking:** seguimiento de identidades estables con ByteTrack.
3. **Posesión:** estimación de posesión por proximidad con modelo de estado y métricas agregadas.

Una contribución metodológica de este trabajo es el registro exhaustivo de las decisiones de diseño con evidencia experimental cuantitativa, evitando evaluaciones subjetivas. Como ejemplo, la asignación de equipo por color HSV parecía correcta al inspeccionar frames individuales, pero la evaluación

cuantitativa contra ground truth reveló un accuracy equivalente al azar ($\sim 60\%$), lo que motivó el cambio a embeddings visuales.

II. ARQUITECTURA DEL PIPELINE

El sistema procesa un video de fútbol en cuatro etapas secuenciales (Fig. 1):

1. **Detección (YOLO26m):** cada frame se procesa con el detector para obtener cajas de jugadores, arqueros, árbitros y pelota. Las detecciones se traducen a un formato neutro (*Detection*) que desacopla el resto del pipeline del modelo específico.
2. **Tracking (ByteTrack):** las detecciones se asocian temporalmente para asignar IDs estables a cada objeto a lo largo del video. Opera solo sobre IoU entre cajas, sin embeddings de apariencia.
3. **Asignación de equipo (SigLIP):** los recortes de cada jugador se procesan con un encoder visual SigLIP para obtener embeddings, que se reducen con UMAP y se agrupan con KMeans en 2 equipos. La asignación se agrega por track (voto mayoritario).
4. **Posesión y métricas:** se estima el poseedor instantáneo (jugador más cercano a la pelota) y se aplica un modelo de hold con histéresis para producir una serie temporal de posesión continua. Se calculan métricas agregadas y se genera un video con overlay.

El orden de las etapas difiere de la propuesta original (donde la asignación de equipo precedía al tracking). La evidencia experimental mostró que la asignación robusta requiere agregar sobre la vida de cada track, lo que presupone tener los IDs estables del tracker (Sección V).

III. DATASET

III-A. Entrenamiento del detector

El detector se entrenó sobre un dataset de fútbol alojado en Roboflow (`footballdetection-tiny4/finalv2`), con 4 clases: `ball`, `goalkeeper`, `player` y `referee`. El formato de exportación es compatible con las tres arquitecturas YOLO comparadas.

overlay_frame.png

Figura 1. Salida del pipeline: frame de SNMOT-108 con detecciones coloreadas por equipo (rojo/azul), pelota (amarillo), poseedor marcado con círculo, y scoreboard con porcentaje de posesión acumulado.

III-B. Evaluación: SoccerNet-Tracking

Para la evaluación del pipeline completo se utilizó SoccerNet-Tracking [1], un subconjunto de SoccerNet que provee clips de ~ 30 s desde la cámara táctica (1920×1080 , 25 fps, ~ 750 frames). Cada clip incluye anotaciones de tracking (caja + ID por frame) y un archivo `gameinfo.ini` que mapea cada track a su equipo y rol, proporcionando ground truth para validar tracking y asignación de equipo.

Se seleccionaron 5 clips de los 57 disponibles en el split `train`, cubriendo 3 esquemas de color distintos para estresar la asignación de equipo (Tabla I).

Cuadro I
CLIPS DE SOCCERNET-TRACKING SELECCIONADOS

Clip	Colores	Acción	Rol
SNMOT-108	rojo vs gris	Clearance	primario
SNMOT-169	rojo-negro vs blanco	Clearance	backup
SNMOT-061	verde vs blanco	Shots on target	backup
SNMOT-157	rojo-negro vs blanco-azul	Clearance	backup
SNMOT-065	verde vs blanco	Clearance	backup

IV. SELECCIÓN DEL MODELO DE DETECCIÓN

IV-A. Modelos comparados

Se compararon tres arquitecturas de detección de la familia Ultralytics, todas en tamaño `m` para garantizar una comparación justa:

- **YOLOv8m**: baseline clásico, ampliamente citado.
- **YOLO11m**: generación intermedia.

- **YOLO26m**: generación más reciente.

La elección del tamaño `m` (en lugar de `x`) se justifica por el contexto de video: la estimación de posesión requiere procesar frames a buen ritmo, y el tamaño `m` ofrece el mejor compromiso precisión/velocidad para objetos grandes como jugadores.

IV-B. Hiperparámetros de entrenamiento

Idénticos para los tres modelos (Tabla II), de modo que lo único que varía es la arquitectura.

Cuadro II
HIPERPARÁMETROS DE ENTRENAMIENTO

Parámetro	Valor	Justificación
epochs	80	Curvas estabilizadas
imgsz	640	Default, suficiente
hsv_s / hsv_v	0.5 / 0.5	Robustez a iluminación
translate	0.1	Posición de objetos
scale	0.6	Zoom de cámara
perspective	0.0005	Ángulo de cámara
shear	40	Variabilidad geométrica
flipr	0.5	Simetría izq/der

IV-C. Resultados de la comparación

La Tabla III presenta las métricas globales sobre el conjunto de validación.

Cuadro III
MÉTRICAS GLOBALES (ÚLTIMA ÉPOCA, SET DE VALIDACIÓN)

Modelo	mAP50	mAP50-95	Prec.	Recall
YOLO11m	0.941	0.557	0.919	0.907
YOLO26m	0.954	0.595	0.922	0.934
YOLOv8m	0.957	0.558	0.955	0.920

El recall por clase (Tabla IV) muestra que la pelota, el cuello de botella esperado del pipeline, está empatada en ~ 0.89 para los tres modelos.

Cuadro IV
RECALL POR CLASE

Clase	YOLO11m	YOLO26m	YOLOv8m
ball	0.88	0.89	0.89
goalkeeper	0.90	0.95	0.87
player	0.98	0.98	0.99
referee	0.90	0.93	0.95

IV-D. Modelo elegido: YOLO26m

Se seleccionó **YOLO26m** como detector del pipeline por:

- Mejor mAP50-95 (0.595): la métrica más exigente, que mide localización fina de las cajas. Esto es crítico porque la posesión se decide por distancia jugador-pelota.
- Mejor recall global (0.934) y mejor detección de goalkeeper.

- La pelota está empatada, por lo que no se sacrifica la clase crítica.

La contrapartida asumida es que YOLO26m genera más falsos positivos de `player` sobre el fondo (0.71 vs 0.58 de YOLOv8m), mitigado con umbral de confianza (`conf=0.5`).

V. DETECCIÓN Y ASIGNACIÓN DE EQUIPO

V-A. Formato de detección

Cada detección se traduce a un `dataclass` propio (`Detection(bbox, cls, conf, team, track_id)`) que desacopla el pipeline del detector específico. Los campos `team` y `track_id` se completan en etapas posteriores, de modo que la detección se enriquece progresivamente.

V-B. Asignación de equipo: del color a los embeddings

La propuesta original planteaba asignación de equipo por clustering en espacio de color HSV. Se implementaron múltiples enfoques basados en color, todos evaluados cuantitativamente contra el ground truth de SoccerNet (Tabla V).

Cuadro V
EVOLUCIÓN DE LA ASIGNACIÓN DE EQUIPO

Enfoque	Resultado
Color per-frame (HSV + variantes)	whack-a-mole
DBSCAN (varios ϵ)	nunca 2 clusters
Color agregado por track + KMeans	59–62 % (azar)
Embeddings SigLIP + track	92–98 %

V-B1. Fracaso de los enfoques por color: La causa raíz del fracaso es la **contaminación de fondo**: cuando un jugador está lejos, el recorte mezcla la camiseta con el césped o con elementos del estadio (butacas, publicidad). Como el fondo varía por partido, ninguna heurística per-frame generaliza. DBSCAN no ayudó porque la contaminación crea un continuo entre los dos colores, sin valle de densidad para separar.

La agregación temporal por track (mediana del color sobre la vida del jugador) redujo el ruido pero alcanzó solo ~60 % de accuracy, equivalente al azar para 2 equipos. Crucialmente, la inspección visual de frames individuales *parecía* correcta, pero la evaluación cuantitativa contra ground truth reveló el problema real.

V-B2. Solución: embeddings visuales SigLIP:

Se adoptaron embeddings visuales mediante SigLIP (google/siglip-base-patch16-224): recorte de cada jugador → embedding visual → UMAP → KMeans, agregado por track (voto mayoritario de los crops). El embedding es robusto a la contaminación de fondo por diseño, ya que captura la semántica del objeto.

V-B3. Cambio de orden del pipeline: La necesidad de agregar por track forzó un reordenamiento del pipeline respecto de la propuesta original:

Propuesta: detección → equipo → tracking → posesión
Ejecución: detección → tracking → equipo → posesión

Cuadro VI
ACCURACY DE ASIGNACIÓN DE EQUIPO: COLOR VS EMBEDDINGS

Clip	Color/track	SigLIP
SNMOT-108 (rojo/gris)	59.5 %	92.0 %
SNMOT-061 (verde/blanco)	62.1 %	97.8 %

Esta desviación está justificada por los datos: la asignación robusta requiere agregar sobre la vida de cada jugador, lo que presupone tener los track IDs.

VI. TRACKING

El seguimiento multi-objeto asocia las detecciones de cada frame para mantener identidades (IDs) estables a lo largo del video. Se utiliza ByteTrack [3], integrado en Ultralytics mediante `model.track(..., persist=True)`, que ejecuta detección y tracking en una sola pasada. El modo `persist` mantiene el estado interno del tracker entre llamadas, de modo que los IDs se propagan frame a frame sin reiniciarse.

VI-A. Diseño del módulo

El módulo `tracking.py` recibe una secuencia de frames y devuelve, por cada frame, una lista de `Detection` con el campo `track_id` completo. Esta interfaz permite que las etapas siguientes (asignación de equipo, posesión) trabajen con identidades estables sin conocer los detalles del tracker.

ByteTrack se eligió por su simplicidad (no requiere embeddings de apariencia, solo IoU entre cajas) y por estar disponible como configuración nativa de Ultralytics (`bytetrack.yaml`). Al operar solo sobre geometría, no agrega costo computacional significativo sobre la detección.

VI-B. Rol en el pipeline

La necesidad de tracking *antes* de la asignación de equipo (una desviación respecto de la propuesta original, descrita en la Sección V) hace del tracker un componente crítico: la calidad de los track IDs determina la calidad de la agregación temporal de embeddings y, por tanto, de la asignación de equipo. En las pruebas sobre SNMOT-108 (150 frames), ByteTrack produjo IDs estables con baja fragmentación, lo que habilitó la agregación por track que llevó la asignación de equipo de ~60 % a 92–98 %.

VII. ESTIMACIÓN DE POSESIÓN

VII-A. Método

La estimación de posesión se estructura en dos niveles: la identificación del poseedor instantáneo en cada frame y un modelo temporal que produce una serie de posesión continua.

VII-A1. Poseedor instantáneo: En cada frame, el poseedor es el jugador (`player`) más cercano a la pelota, con las siguientes decisiones de diseño:

- Distancia desde los pies:** se mide desde el borde inferior del `bbox` del jugador (punto medio de los pies) al centro de la pelota, no desde el centro del torso.

- **Umbral relativo:** la distancia se normaliza por la altura del bbox del jugador ($d_{\text{norm}} = d/h_{\text{bbox}}$), logrando invarianza aproximada a la perspectiva de la cámara.
- **Exclusión del arquero:** el goalkeeper no entra en los candidatos a posesión, ya que el saque o descuelgue del arquero no representa posesión en sentido táctico.
- **Pelota no detectada:** si no hay detección confiable de pelota en un frame, la posesión instantánea queda indefinida.

VII-A2. Modelo temporal: hold con histéresis: La posesión instantánea presenta dos problemas que impiden usarla directamente para métricas agregadas. Primero, la pelota pasa tiempo viajando (pases, pelotazos), generando frames sin poseedor que fragmentan la serie. Segundo, en disputas la posesión “parpadea” entre equipos.

Se adoptó un **modelo de hold con histéresis**:

1. Un poseedor claro (distancia normalizada $< u$, con $u = 0.5$) genera un *evento de control* que ancla la posesión a su equipo.
2. Entre eventos de control, la posesión se **sostiene** con el último equipo (los pases no la rompen).
3. La posesión solo **cambia** cuando el otro equipo acumula $\geq h$ eventos de control consecutivos ($h = 4$), filtrando disputas momentáneas.

VII-B. Métricas agregadas

A partir de la serie de posesión se calculan: porcentaje de posesión por equipo, cantidad de cambios de posesión y duración media de las secuencias de posesión continua. Los frames sin posesión definida no cuentan para los porcentajes y cortan las secuencias.

VIII. EXPERIMENTOS Y RESULTADOS

VIII-A. Detección de la pelota: el cuello de botella

El primer pipeline completo sobre 400 frames de SNMOT-108 produjo solo 7 % de frames con posesión. Se aisló la causa con un script de diagnóstico que barre umbrales y cuenta detecciones de pelota (Tabla VII).

Cuadro VII
DETECCIÓN DE PELOTA Y COBERTURA DE POSESIÓN (SNMOT-108, 400 FRAMES)

Config.	Pelota det.	Poseedor	Poseión
640, conf 0.5	10 %	10 %	7 %
1280, conf 0.5	25 %	16 %	16 %
1280, conf 0.15	53 %	16 %	16 %
Interpolación (≤ 5 fr.)	27 %	16 %	16 %
Pelota GT	99 %	47 %	—

Hallazgo: el cuello de botella es la detección de la pelota, no el umbral de posesión. Bajar la confianza a 0.15 agrega falsos positivos sin mejorar la posesión. La pelota está presente en el 99 % de los frames (según el GT), pero el detector la encuentra solo en el 25 %: un **domain gap** entre el dataset de entrenamiento (Roboflow, planos cerrados)

y SoccerNet (cámara táctica abierta, pelota más chica). Se adoptó `imgsz=1280` como configuración final.

VIII-B. Calibración del modelo de posesión

Para aislar la lógica de posesión del error de detección de pelota, se inyectó la posición real de la pelota (del GT de SoccerNet) y se barrieron los parámetros del modelo (Tabla VIII).

Cuadro VIII
BARRIDO DE HISTÉRESIS (PELOTA GT, 750 FRAMES, UMBRAL 0.5)

h	Cob.	%A/ %B	Cambios	Dur. media
4	65 %	67/33	8	2.2 s
8	55 %	55/45	3	4.9 s
20	63 %	63/37	1	9.8 s

Las métricas son sensibles al valor de histéresis. Se adoptó $h = 4$ como default (el más balanceado, sin colapso en ningún clip).

VIII-C. Evaluación contra ground truth manual

Se anotó manualmente la posesión de SNMOT-108 (6 tramos). Se evaluó la posesión frame a frame, excluyendo tramos anotados como “ninguno” (arquero, pelota fuera). Con los parámetros calibrados (umbral 0.5, $h = 4$), se realizó un barrido conjunto umbral $\times$ histéresis contra el GT (Tabla IX).

Cuadro IX
ACCURACY DE POSESIÓN VS GT MANUAL (PELOTA GT, SNMOT-108)

Umbral	$h = 2$	$h = 4$	$h = 8$
0.50	76 %	76 %	74 %
0.75	73 %	73 %	71 %
1.00	70 %	70 %	68 %

La mejor configuración (umbral 0.5, $h \in \{2, 4\}$) alcanza **~76 %** de accuracy frame a frame. El umbral 0.5 es robusto a la histéresis; umbrales más amplios degradan el resultado al incluir jugadores que no controlan realmente la pelota.

VIII-D. Resumen de resultados

La Tabla X consolida los resultados de cada componente del pipeline.

Cuadro X
RESULTADOS FINALES DEL PIPELINE

Componente	Resultado
Detección (mAP50 / mAP50-95)	0.954 / 0.595
Recall de pelota (validación)	0.89
Recall de pelota (SoccerNet, 1280)	~0.25
Asignación de equipo	92–98 % vs GT
Poseión (pelota GT, $u=0.5, h=4$)	~76 % vs GT manual

VIII-E. Entrenamiento del modelo de detección

La Fig. 2 muestra las curvas de entrenamiento del modelo elegido (YOLO26m). Las pérdidas de entrenamiento y validación convergen establemente antes de la época 80, y las métricas (mAP50, mAP50-95) alcanzan mesetas claras, confirmando que el presupuesto de entrenamiento es suficiente. La Fig. 3 presenta la matriz de confusión normalizada, donde se observa el alto recall de las 4 clases y la principal fuente de falsos positivos (background $\rightarrow$ player, 0.71).




Figura 2. Curvas de entrenamiento de YOLO26m: pérdidas (box, cls, dfl) y métricas (precision, recall, mAP50, mAP50-95) sobre 80 épocas.




Figura 3. Matriz de confusión normalizada de YOLO26m. Se destaca el alto recall de todas las clases y la confusión background $\rightarrow$ player (0.71).

VIII-F. Discusión

El pipeline logra resultados sólidos en detección de jugadores y asignación de equipo, pero la estimación de posesión está limitada por la detección de la pelota. El domain gap entre Roboflow y SoccerNet (recall de pelota de 89% $\rightarrow$ 25%) es la brecha más importante del sistema.

La principal fuente de varianza residual es el no-determinismo de UMAP en la asignación de equipo: la accuracy de equipos varía entre corridas (de $\sim 57\%$ a $\sim 95\%$), lo que arrastra la posesión. En una corrida con buena asignación (94.8%), la posesión alcanza 76%; con una mala, cae a 57%.

VIII-G. Limitaciones

- **Domain gap en detección de pelota:** el detector no generaliza a la escala de pelota de SoccerNet. La detección cae de 89% a $\sim 25\%$, aun con `imgsz=1280`.
- **No-determinismo de UMAP:** la asignación de equipo varía entre corridas. A futuro: fijar semilla o votar varias corridas.
- **Calibración de posesión:** los parámetros fueron calibrados sobre un solo clip con ground truth manual. La generalización requiere más anotaciones.

IX. CONCLUSIONES

Se construyó un pipeline completo de visión por computadora para la estimación de posesión de pelota en video de fútbol. Las principales conclusiones son:

1. La detección de jugadores con YOLO26m alcanza métricas sólidas (mAP50-95 = 0.595), y la elección del modelo se justifica por la necesidad de localización fina de las cajas para la estimación de posesión.
2. La asignación de equipo por color (HSV/RGB, con y sin agregación temporal) es insuficiente ($\sim 60\%$). Los embeddings visuales SigLIP resuelven el problema (92–98%), pero requieren reordenar el pipeline (tracking antes de asignación).
3. La posesión per-frame basada en proximidad es correcta localmente, pero requiere un modelo temporal (hold + histéresis) para producir métricas no degeneradas.
4. El principal cuello de botella del sistema es la detección de la pelota, debido al domain gap entre el dataset de entrenamiento y las condiciones de evaluación.
5. La evaluación cuantitativa contra ground truth fue esencial para identificar problemas que la inspección visual ocultaba.

IX-A. Trabajo futuro

- Fine-tuning del detector de pelota sobre clips de SoccerNet o inferencia a resolución 1920 para cerrar el domain gap.
- Determinismo en la asignación de equipo (semilla fija de UMAP o votación de múltiples corridas).
- Anotación de más clips para calibración robusta de los parámetros de posesión.

REFERENCIAS

- [1] S. Giancola, A. Cioppa, A. Delière, F. Silvio, D. Ghanem, B. Ghanem, M. Van Droogenbroeck, "SoccerNet: A scalable dataset for action spotting in soccer videos," in *Proc. IEEE/CVF CVPR Workshops*, 2018.
- [2] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLO," 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics>
- [3] Y. Zhang, P. Sun, Y. Jiang, D. Yu, F. Weng, Z. Yuan, P. Luo, W. Liu, and X. Wang, "ByteTrack: Multi-object tracking by associating every detection box," in *Proc. ECCV*, 2022.
- [4] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, "Sigmoid loss for language image pre-training," in *Proc. ICCV*, 2023.
- [5] Roboflow, "Roboflow: Computer vision tools for developers and enterprises," 2024. [Online]. Available: <https://roboflow.com>
- [6] L. McInnes, J. Healy, and J. Melville, "UMAP: Uniform manifold approximation and projection for dimension reduction," *arXiv:1802.03426*, 2018.